Giải pháp tách từ tiếng Ê Đê dựa vào kho từ vựng tiếng Ê Đê

Hoàng Thị Mỹ Lệ[1], Phan Huy Khánh[2], Võ Văn Trung[2]

[1] Trường Đại học Sư phạm Kỹ thuật, Đại học Đà Nẵng
[2] Trường Đại học Bách Khoa, Đại học Đà Nẵng
htmle@ute.udn.vn, khanhph@dut.udn.vn, trungvv@gmail.com

Tóm tắt. Tách từ là một quá trình xử lý nhằm mục đích xác định ranh giới của các từ trong câu. Các từ cũng có thể là các từ đơn, từ ghép… Trong xử lý ngôn ngữ tự nhiên, để có thể xác định cấu trúc ngữ pháp của câu, từ loại của một từ trong câu, yêu cầu đặt ra là phải xác định được từ trong câu. Bài toán tách từ luôn là bài toán đặt ra đầu tiên để giải quyết bài toán dịch tự động hay các bài toán trong xử lý ngôn ngữ tự nhiên. Bên cạnh các bài toán nghiên cứu tách từ tiếng Việt, bài toán tách từ tiếng Ê Đê cho đến nay vẫn chưa có công trình nghiên cứu nào công bố và chia sẻ cho mục đích nghiên cứu xử lý tiếng Ê Đê. Để giải quyết vấn đề này và dựa trên thực trạng về xử lý tiếng dân tộc thiểu số ở Việt Nam nói chung và tiếng Ê Đê nói riêng, bài báo đề xuất giải pháp tách từ tiếng Ê Đê theo phương pháp so khớp cực đại dựa vào kho dữ liệu từ vựng tiếng Ê Đê, nhằm góp phần giải quyết bài toán tách từ trong xử lý tiếng Ê Đê.

Từ khóa: xử lý tiếng Ê Đê, tách từ tiếng Ê Đê, kho dữ liệu từ vựng, dân tộc thiểu số Ê Đê, phương pháp so khớp cực đại.

1 Đặt vấn đề

Để giải quyết bài toán dịch tự động hay rất nhiều bài toán xử lý ngôn ngữ tự nhiên khác thì bài toán tách từ luôn là bài toán đầu tiên và quan trọng nhất. Các ngôn ngữ theo loại hình ngôn ngữ đơn lập (tiếng Nhật, tiếng Trung Quốc, tiếng Thái, tiếng Việt…) ranh giới từ không phải là những kí tự trắng như trong các ngôn ngữ thuộc loại hình hòa kết (tiếng Anh, tiếng Pháp, tiếng Nga…) mà có sự liên hệ chặt chẽ giữa các tiếng với nhau. Một từ có thể cấu tạo bởi một hoặc nhiều tiếng [1]. Vì vậy với các ngôn ngữ đơn lập, vấn đề đặt ra của bài toán tách từ là xác định được ranh giới giữa các từ.

Trong tiếng Anh mỗi từ mang một nghĩa và được xác định ranh giới bằng kí tự trắng. Tiếng Việt là ngôn ngữ đơn lập do vậy có rất nhiều từ ghép. Vì vậy, khi dịch máy từ tiếng Việt sang tiếng Anh nếu không tách đúng từ thì sẽ xuất hiện dịch từng từ rồi ghép lại với nhau.

Với tiếng Anh do là ngôn ngữ biến hình nên việc xác định từ loại dễ hơn, ngoài ra nó cũng ít từ đồng tự. Về từ đa nghĩa tiếng Anh, tiếng Việt và gần như tất cả các

ngôn ngữ khác đều rất phức tạp. Vì vậy, muốn xác định được nghĩa chính xác của một từ thì phải thực hiện phân tích ngữ cảnh.

Từ trong tiếng Anh, tiếng Việt và tiếng Ê Đê có các điểm khác về đơn vị cơ bản; tiền tố, hậu tố; từ loại và ranh giới từ. Bảng 1, cho thấy bài toán tách từ tiếng Việt, tiếng Ê Đê gặp phải khó khăn về vấn đề xử lý nhập nhằng.

Bảng 1. *So sánh điểm khác biệt chính giữa tiếng Anh, tiếng Việt và tiếng Ê Đê*

Đặc điểm	Tiếng Anh	Tiếng Việt	Tiếng Ê Đê
Đơn vị cơ bản	Từ	Tiếng	Tiếng
Tiền tố/Hậu tố	Có	Không có	Không có
Từ loại	Được định nghĩa rõ	Không định nghĩa rõ	Không định nghĩa rõ
Ranh giới từ	Khoảng trắng hoặc dấu câu	Tổ hợp có nghĩa dựa vào ngữ cảnh	Tổ hợp có nghĩa dựa vào ngữ cảnh

Các phương pháp tiếp cận trong bài toán tách từ [5]:

- *Phương pháp so khớp cực đại* (MM- Maximum Matching), là phương pháp tách từ dựa trên từ điển. Phương pháp MM cố gắng so khớp với từ dài nhất có thể có trong từ điển. Độ chính xác của thuật toán này phụ thuộc vào độ lớn của từ điển. Phương pháp MM hoàn toàn không thể giải quyết vấn đề nhập nhằng và không thể nhận diện được các từ không có trong từ điển. Phương pháp này chỉ tách đúng những từ có trong từ điển.
- *Phương pháp Học dựa trên sự biến đổi* (TBL- Transformation-Based Learning), là phương pháp tiếp cận dựa trên tập ngữ liệu đã đánh dấu. Theo cách tiếp cận này để máy tính có thể nhận biết ranh giới giữa các từ, để có thể tách từ chính xác. Máy được học các câu mẫu trong tập ngữ liệu đã được đánh dấu ranh giới giữa các từ đúng. Phương pháp rất đơn giản, vì chỉ cần cho máy học các tập câu mẫu và sau đó máy sẽ tự rút ra qui luật của ngôn ngữ và để từ đó sẽ áp dụng chính xác khi có những câu đúng theo luật mà máy đã rút ra. Độ chính xác của thuật toán này phụ thuộc vào tập ngữ liệu thật đầy đủ và phải được huấn luyện lâu để máy có thể rút ra các luật đầy đủ.
- *Phương pháp chuyển đổi trạng thái hữu hạn có trọng số* (WFST-Weighted Finite State Transducer), là phương pháp dựa trên ý tưởng áp dụng WFST với trọng số là xác suất xuất hiện của mỗi từ trong kho ngữ liệu. Mô hình này đạt được độ chính xác tương đối cao, bằng việc sử dụng thêm mạng Neural kết hợp với từ điển để khử các nhập nhằng có thể có khi tách ra được nhiều từ trong một câu và khi đó tầng mạng Neural sẽ loại bỏ đi các từ không phù hợp bằng cách kết hợp với từ điển. Bên cạnh đó, cũng tương tự như phương pháp TBL điểm quan trọng của mô hình này cần tập ngữ liệu học đầy đủ.
- *Phương pháp Maximum Entropy*, là phương pháp dựa trên ý tưởng của mô hình gắn nhãn từ loại dùng phương pháp Maximum Entropy cho tiếng Anh của Ad-wait Ratnaparkhi. Đây là một hướng mới cho các phương pháp tách từ hiện nay. Nếu kho ngữ liệu được gắn nhãn đầy đủ thì các nhập nhằng có thể được khử.

Tuy nhiên, vẫn chưa có một công trình nào thống kê được mức độ chính xác của phương pháp này.

Với bài toán tách từ, ta có thể thấy mỗi phương pháp đều có những ưu điểm và những hạn chế riêng, nhưng tất cả đều cần có một kho ngữ liệu đủ lớn để kết quả tách từ đạt được độ chính xác cao.

2 Giới thiệu tiếng Ê Đê

Tiếng Êđê thuộc ngữ hệ Malayo-Polynesien (Nam Đảo) có quan hệ với nhiều ngôn ngữ Nam Đảo lục địa [10], [10].

2.1 Đặc điểm ngữ âm Ê Đê

Tiếng Ê Đê là ngôn ngữ vừa đơn lập, vừa đa tiết, không có thanh điệu. Quá trình biến đổi hình thái học từ ngôn ngữ đa tiết có phụ âm tố đã ảnh hưởng không nhỏ đến những đặc điểm ngữ âm của tiếng Ê Đê [3], [4], [8]. Trong tiếng Ê Đê, phần đầu âm tiết chưa bị đơn tiết hoá triệt để, nên cấu trúc ngữ âm và âm vị học của nó phức tạp. Các hiện tượng biến đổi hình thái của từ không nhiều và được diễn ra ngay trong bản thân vỏ âm tiết làm cho âm tiết có cấu trúc ngữ âm không ổn định, hình thái thay đổi làm cho nghĩa của từ cũng thay đổi theo, ví dụ:

djiê chết → *mdjiê* làm cho chết - giết
bŏ đầy → *mbŏ* làm cho đầy

Xu hướng đơn tiết hoá ở tiếng Ê Đê chính là nguyên nhân của sự biến đổi hình thái học [8].

Bảng 2. *Bảng chữ cái tiếng Ê Đê*

Phụ âm	***Chữ hoa***	B	Ɓ	Č	D	Đ	G	H	J	K	L
		M	N	Ñ	P	R	S	T	W	Y	
	Chữ thường	b	ɓ	č	d	đ	g	h	j	k	l
		m	n	ñ	p	r	s	t	w	y	
Nguyên âm	***Chữ hoa***	A	Ă	Â	E	Ĕ	Ê	Ễ	I	Ĭ	O
		Ŏ	Ô	Ỗ	Ơ	Ở	U	Ŭ	Ư	Ử	
	Chữ thường	a	ă	â	e	ĕ	ê	ễ	i	ĭ	o
		ŏ	ô	ỗ	ơ	ở	u	ŭ	ư	ử	

2.2 Đặc điểm về từ vựng

Vốn từ vựng tiếng Ê Đê bao gồm nhiều lớp từ, nhiều yếu tố từ vựng có nguồn gốc từ nhiều nhóm ngôn ngữ khác nhau ở khu vực Đông Nam Á.

Từ trong tiếng Ê Đê là các từ đơn tiết, số lượng từ đa tiết rất ít. Phương thức cấu tạo từ chủ yếu hiện nay trong tiếng Ê Đê là phương thức ghép. Quá trình đơn tiết hoá và

vay mượn từ vựng đã góp phần thúc đẩy những chuyển biến nghĩa của từ đồng âm, đồng nghĩa trong tiếng Ê Đê [4], [8], [10].

2.3 Đặc điểm ngữ pháp

Ngữ pháp tiếng Ê Đê mang đặc điểm cơ cấu ngữ pháp của các ngôn ngữ đơn lập. Diễn đạt các ý nghĩa ngữ pháp, phương thức ngữ pháp trong tiếng Ê Đê là phương thức trật tự từ và hư từ. Mô hình cấu trúc câu trong tiếng Ê Đê được xác định khá rõ ràng, mang đặc thù tiếng Ê Đê.

Trong câu tường thuật, chủ ngữ đứng trước vị ngữ, còn bổ ngữ đứng sau vị ngữ. Định ngữ thường đứng sau thành phần mà nó bổ ngữ, riêng trạng ngữ vị trí có thể thay đổi.

Trường hợp phụ từ biểu thị mức độ đứng sau tính từ hoặc động từ. Ví dụ:

- *snăk* (rất) là từ đơn
  siam ***snăk*** (**rất** đẹp)
- *êdi*, *đei* đồng nghĩa với *snăk*
- *snăk s'ưm*, *tliă tliêt* là các từ ghép nghĩa cũng như như snăk nhưng mức độ cao hơn.

Trong câu nghi vấn của tiếng Ê Đê, từ dùng để hỏi thường được đặt ở đầu câu (đặc điểm này khác câu nghi vấn trong tiếng Việt):

Để hỏi nơi chốn, từ *Ti anôk* (ở đâu) đứng ở đầu câu hỏi. Ví dụ:

Ti anôk *sang ih*? Nhà anh ở đâu?

Để hỏi làm việc gì hoặc nghề gì, từ Ya bruă (làm nghề gì) đứng ở đầu câu hỏi. Ví dụ:

Ya bruă *ih ngă*? Anh làm nghề gì?

Để hỏi cái gì, từ Ya mnŏng (cái gì) đứng ở đầu câu hỏi. Ví dụ:

Ya mnŏng *ih čiăng ngă*? Anh muốn làm cái gì?

Để hỏi như thế nào hay thế nào, từ Si ngă đứng ở đầu câu hỏi. Ví dụ:

Si ngă *kleih hdĭp gŏ êsei ih*? Cuộc sống gia đình anh thế nào?

Các dấu câu (dấu phẩy, dấu chấm, dấu chấm hỏi...) trong tiếng Ê Đê được sử dụng như tiếng Việt. Nguyên tắc viết hoa của tiếng Ê Đê cũng giống như nguyên tắc viết hoa của tiếng Việt [4], [8].

3 Giải pháp tách từ tiếng Ê Đê

Việc chọn phương pháp tiếp cận trong bài toán tách từ phải phù hợp với thực trạng xử lý tiếng Ê Đê hiện nay và đặc thù tiếng Ê Đê, cụ thể:

Phương pháp Maximum Entropy, đòi hỏi kho ngữ liệu được gắn nhãn đầy đủ. Thực tế, cho đến nay chưa có kho ngữ liệu tiếng Ê Đê được gắn nhãn đầy đủ để áp dụng phương pháp này.

Phương pháp chuyển đổi trạng thái hữu hạn có trọng số, đòi hỏi phải cần tập ngữ liệu đầy đủ. Trong xử lý tiếng Ê Đê hiện nay vẫn chưa có tập ngữ liệu học đầy đủ.

Phương pháp Học dựa trên sự biến đổi, đòi hỏi tập ngữ liệu thật đầy đủ và phải được huấn luyện lâu để máy có thể rút ra các luật đầy đủ. Các kết quả nghiên cứu tiếng Ê Đê cho đến nay vẫ chưa có tập ngữ liệu đầy đủ để tiếp cận phương pháp này.

Từ những phân tích trên, chúng tôi đề xuất chọn phương pháp so khớp cực đại dựa vào kho từ vựng tiếng Ê Đê làm phương pháp tiếp cận trong bài toán tách từ tiếng Ê Đê.

3.1 Đặc điểm kho từ vựng tiếng Ê Đê

Các từ tiếng Ê Đê chủ yếu được thu thập và ghi theo tiếng Ê Đê thuộc nhóm Kpă. Các mục từ tiếng Ê Đê phản ảnh phần nào vốn văn hóa truyền thống của người Ê Đê [7], [9]. Tiếng Ê Đê được ghi bằng chữ Ê Đê và lưu trên máy tính với phông chữ Unicode.

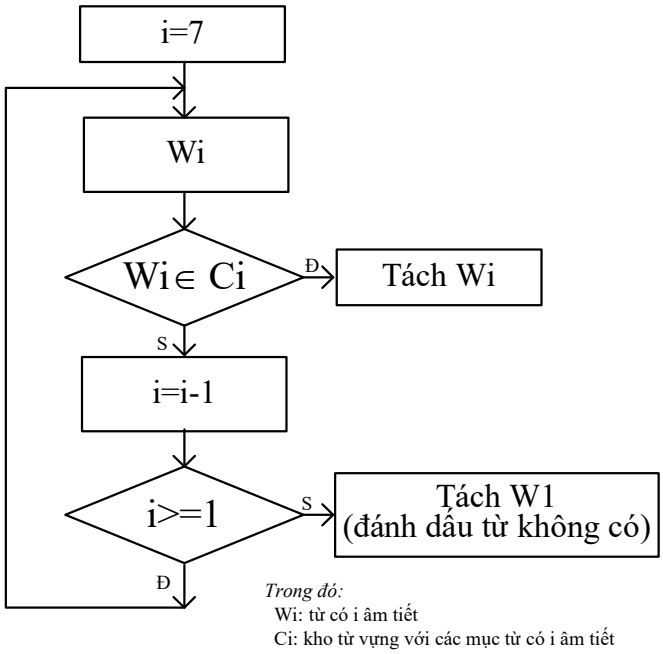
Số lượng có 9.288 mục từ tiếng Ê Đê trong kho từ vựng theo số lượng âm tiết trong mục từ, được thống kê trong bảng 3 [7].

Bảng 3. *Thống kê số lượng các mục từ tiếng Ê Đê theo số lượng âm tiết*

Số âm tiết	**1**	**2**	**3**	**4**	**5**	**6**	**7**
Số mục từ	3.339	4.976	818	139	13	2	1

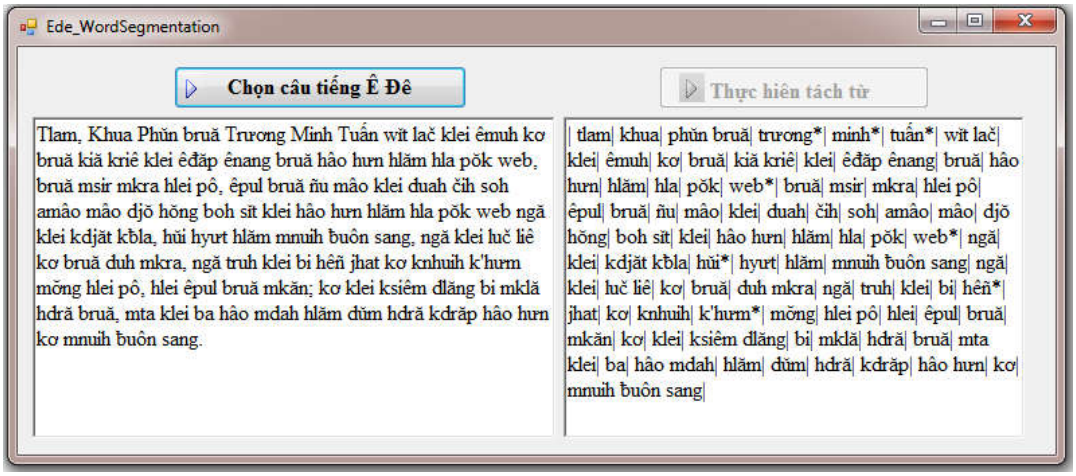
3.2 Đề xuất phương pháp tách từ tiếng Ê Đê

Giải pháp tách từ tiếng Ê Đê theo phương pháp so khớp cực đại dựa vào kho từ vựng. Với kho từ vựng tiếng Ê Đê như bảng 3, chúng tôi đề xuất tách thành 7 kho từ vựng theo số âm tiết của mục từ để thực hiện so khớp cực đại với độ dài là từ 7 âm tiết. Giải pháp tách từ được thể hiện trong hình 1.



Hình 1. *Giải pháp tách từ tiếng Ê Đê dựa vào kho từ vựng*

Dựa vào giải pháp tách từ tiếng Ê Đê đã đề xuất như trên, chúng tôi đã xây dựng công cụ WSE (Word Segmentation Ede) dùng để tách từ tiếng Ê Đê. Nguồn dữ liệu đầu vào của bộ công cụ là các câu tiếng Ê Đê trong các bản tin của Hệ phát thanh dân tộc VOV4. Các từ không có trong kho từ vựng tiếng Ê Đê được đánh dấu * theo sau. Hình 2 là giao diện của bộ công cụ WSE, minh họa tách từ tiếng Ê Đê.



Hình 2. Bộ tách từ tiếng Ê Đê WSE

3.3 Kết quả thực nghiệm

Chúng tôi đã tiến hành thực nghiệm bộ WSE với nguồn dữ liệu đầu vào là các bản tin của Hệ phát thanh dân tộc VOV4 [2]. Các bản tin này đảm bảo được gõ đúng kỹ thuật và đã được kiểm tra. Phông chữ dùng trong bản tin là phông chữ TayNguyenKey, kiểu gõ VNI và bộ gõ UniKey. Chúng tôi đã áp dụng bộ chuyển đổi CEDU [6] để chuyển đổi tất cả các tập kí tự được gõ theo phông chữ TayNguyenKey về chữ cái tiếng Ê Đê dùng phông chữ Unicode. Bảng 4 trình bày kết quả thực nghiệm với các câu trong 20 bản tin.

Bảng 4. *Kết quả thực nghiệm tách từ trong câu tiếng Ê Đê*

Số từ trong bản tin	Số từ tách được	Số từ tách đúng	Số từ tách không đúng
4.164	3.788	3280	508

Kết quả có được sau khi qua bộ công cụ WSE cũng đã được chúng tôi kiểm tra với các câu đã được tách thủ công và nhận thấy rằng bộ công cụ WSE đã tách được khoảng 85% các từ tiếng Ê Đê đúng. Khoảng 15% các từ còn lại chủ yếu là do: các từ không có trong kho ngữ vựng, các lỗi chính tả (do thủ công đưa vào), các từ tiếng Việt và tiếng Anh.

4 Kết luận

Giải pháp pháp tách từ tiếng Ê Đê theo phương pháp so khớp cực đại dựa vào kho dữ liệu từ vựng tiếng Ê Đê. Kết quả đã tách được các từ tiếng Ê Đê trong các câu khẳng định.

Giải pháp này góp phần giải quyết bài toán tách từ tiếng Ê Đê trong xử lý tiếng Ê Đê. Bài toán tách từ tiếng Ê Đê với công cụ WSE cũng đã đưa ra được các mục từ chưa có trong kho từ vựng tiếng Ê Đê để tiếp tục bổ sung vào kho từ vựng tiếng Ê Đê, góp phần làm giàu kho từ vựng tiếng Ê Đê.

Định hướng tiếp theo, chúng tôi sẽ tiếp tục hoàn thiện bài toán tách từ tiếng Ê Đê khi có được kho ngữ liệu tiếng Ê Đê được gắn nhãn đầy đủ.

Tài liệu tham khảo

[1] Avinesh. PVS, and Karthik G. Dept (2007), *Part-of-speech tagging and chunking using conditional random fields and transformation based learning*, Shallow Parsing for South Asian Languages 2.

[2] Đài tiếng nói Việt Nam. *Hệ phát thanh dân tộc VOV4*. Địa chỉ: http://vov4.vov.vn/Ede.aspx

[3] Đoàn Văn Phúc, "*Từ vựng các phương ngữ Ê Đê*", Nhà xuất bản Thành phố Hồ Chí Minh, 1998.

[4] Đoàn Văn Phúc: *Ngữ âm Ê Đê*, Khoa học xã hội, Hà Nội, 1996.

[5] Dien Dinh, et al, "*A maximum entropy approach for Vietnamese word segmentation*", Proceeding of 4th RIVF Vietnam, pp.12-16, 2006

[6] Hoàng Thị Mỹ Lệ, Phan Huy Khánh, *"Giải pháp chuyển đổi văn bản tiếng Ê Đê dùng phông chữ riêng sang Unicode",* Kỷ yếu Hội nghị khoa học quốc gia FAIR lần thứ X, Đà Nẵng, trang: 205-211, 2017.

[7] Hoàng Thị Mỹ Lệ, Phan Huy Khánh, "*Giải pháp xây dựng kho ngữ vựng song ngữ Việt-Ê Đê dựa trên mô hình tương tác Việt-Ê Đê*", Kỷ yếu Hội thảo Công nghệ Thông tin & Ứng dụng trong các lĩnh vực lần thứ V (CITA'2016), trang 32-37, mã số ISBN: 978-604-80-2094-1, 2016.

[8] Sở Giáo dục - Đào tạo DakLak: *Ngữ Pháp tiếng Ê Đê*, Nhà xuất bản Giáo dục, 2011.

[9] Tạ Văn Thông, "Từ điển Ê Đê-Việt", Viện Từ điển học và Bách khoa thư Việt Nam, 2014.

[10] Y Cang Niê Siêng, Y CôC Mlô, *Hdruôm Hră Hriăm Ê Đê* , Sở Giáo dục Dak Lak, 2007.